

2023 빅콘테스트 정형데이터 분석 분야


클래식 공연 활성화를 위한 효과적인 가격 모델 수립

Team : What's your EDA ?

팀장	이수진	alwaysna0813@naver.com
팀원	류수민	rsm011@naver.com
	문성원	moonjmmm@naver.com
	이가린	r4135@naver.com

CONTENT

Team : What's your EDA ?



- 01 분석 배경
- 02 데이터 클리닝
- 03 EDA
- 04 전처리
- 05 좌석 그룹핑
- 06 결론



01 분석 배경

배경 | 목적 및 필요성 | 분석 수행 범위

문제상황 분석

기존 공연 티켓 가격의 책정



- 투입 제작비 & 목표 수익에 따라 좌석등급을 나눔
- 다른 작품과 비슷하게 좌석 등급 별 가격을 산정하는 방식
- 클래식 공연을 진행하는 예술의 전당도 비슷하게 진행

문제점1. 공연 수요와 고객 특성 파악 X

우리나라 전체 공연시설의 재정자립도 **48.6%**

낮은 재정 자립도는 공연의 질을 낮추고, 소비자 가격이 올라 공연의 접근성이 낮아지며 합리적이지 않은 가격으로 이어져 공연에 대한 **신뢰도**를 잃을 수 있음

문제점2. 효과적이지 못한 티켓 분배

티켓 예매율 & 수요가 높지 않은 **좌석의 구매율**을 높이는 것도 중요
저렴한 가격으로 많은 고객이 방문할 수 있도록 유도한다면 클래식 공연에 대한 관심도 상승과 증가한 예매율을 바탕으로 더 많은 고객 유치 가능

분석 방향

보통의 제품 가격 책정 방법

효용과 원가 사이의 최적 가격

클래식 공연 가격 책정 방법

- 마니아층이 많아 **가격 민감도**가 낮고 **가격 탄력성**이 작음
- 높은 가격으로 인해 경제적 여유가 있는 고객이 구매하는 경향
- 고객의 공연 기획 및 주최사 간 유대감 & 신뢰도가 매우 높음
- 1차적으로 **공연의 수준**이 고객 수요에 가장 큰 영향을 미칠 것이라 예상



공연과 고객 데이터를 통해

수익을 높이는 방향 공연자 측의 생산비용은 고려 X
클래식 공연 고객의 특성
새로운 가격 책정 방법

수요와 소비자의 특성을 반영한 **합리적인 좌석가격** 책정

분석 개요

과제1. 예술의전당 콘서트홀 좌석그룹핑



예술의 전당 공연들은 어떤 특성을 보일까?

각 공연마다 많이 오는 고객들은 누구일까?

고객 유형별로 선호하는 좌석은 어디일까?

» 클러스터링 진행



과제2. 공연별/좌석별 적정 가격을 도출할 수 있는 효과적인 가격 모델을 제시

분석 범위



1 코로나

예술의전당 콘서트홀 좌석 수 : 2505석
코로나로 인한 사회적거리두기로 좌석 띄워앉기, 공연 취소 같은 상황 발생
판매한 전체 좌석 수가 달라 분석에 영향을 끼친다 판단
따라서 해당 시기는 분리하여 따로 분석을 진행

2 고객 정의

본 분석은 좌석 가격 책정으로 수익을 최대화하는 것이 1차적인 목표
따라서 **비회원이면서 초대권으로 온 고객**은 분석에 맞지 않다 판단
따라서 제외 후 분석 진행



02 데이터 클리닝

데이터 수집 | 데이터 정제

기본 작업

전체 행 결측인 membership_type_6 변수 제거

콘서트홀인 경우만 추출

시간 변수 datetime 형식으로 변환

데이터의 play_date를 홈페이지와 비교해본 결과 7일 미뤄져있던 것을 확인, **가명화 처리** 때문이라 판단

2. 홈페이지랑 비교하였을 때 다른 공연이 있는 것 같은 이유는 이번 빅콘테스트용으로 사용하고자 예술의전당의 데이터를 가명정보 처리를 하였기 때문입니다. 분석을위해 홈페이지 내용을 활용하신다면 해당 내용은 내용대로 사용하시면 될 듯합니다.

-빅콘테스트 사무국 메일 답변-

따라서 play_date 7일 앞당겨주며
real_play_date라 rename 해줌

크롤링

분석 데이터

홈페이지

real_play_date
play_st_time

공연 751개

+

예술의전당

title

공연날짜, 입장연령, 관람시간, 가격, 주최, 주관, 후원

추가 데이터

예술의 전당 콘서트홀의 모든 seat에 대한 좌표 데이터인 seat_coor.csv 생성

x	y	seat
25	0	합창석 H블록3열 1
30	0	합창석 G블록4열 37
31	0	합창석 G블록4열 36
...	...	...

- 1 예술의 전당 좌석 배치도를 사용
- 2 층, 블록, 열, 번호를 조합
- 3 좌석배치도에는 존재하지 않지만
분석 데이터에는 존재할 경우 좌석배치도
형식에 따라 넣어줌

크롤링 데이터 클리닝

- 1 공연시간의 차이가 있는 경우
- 2 좌석 등급의 금액이 맞지 않는 경우
- 3 할인 내역이 맞지 않는 경우
- 4 기부 콘서트인 경우



분석 데이터와 합칠 시, 값 오류 또는 NaN 발생
따라서 홈페이지 참고하여 조사 후 값을 바꿔줌

» DISCOUNT_TYPE 확인 결과, 하나의 공연에만 들어가있는 할인내역 존재 EX) 일만원의 나눔, 오만원의 사랑
조사 결과 **기부콘서트의 할인내역**인 것을 확인
따라서 본 분석의 목적인 수익 증대에 맞지 않다고 판단 후 **제거**

분석 데이터 클리닝




- 전석 초대권으로 이루어진 공연은 분석 목적과 맞지 않아 제거
- 분석에 사용되지 않는 열 삭제 `origin_price`, `origin_price2`, `run_time`, `pay_price`, `place`
- `origin_price1`은 **rev_dis**로 rename
- 분석 편의를 위해 **play_date_time**, **tran_date_time** 순으로 재정렬




03 EDA


공연변수 | 고객변수




공연일과 예매일의 차이가 4일 차이에 분포가 몰림 &
 4일 미만의 차이가 나는 경우 확인 X
 당일까지 티켓을 판매하기에 **차이의 최솟값은 0**
 따라서 예매일을 공연일에 맞춰주기 위해 3일 앞당김




러닝타임이 0분, 15분인 공연 발견




교향곡, 클래식, 합창 순으로 인기가 높음




클래식, 성악, 복합장르의 가격대가
다른 장르들 보다 높은 것을 확인
인기에 비해 합창의 가격대가 낮은 것을 알 수 있음




가격 분포대를 살펴본 결과
0원인 경우가 가장 많았음




0원인 경우의 할인받은 내역을 확인
초대권, 기획사 판매가 90%




공연일자 히스토그램 확인
 2020-2021년도의 예매수가 굉장히 낮은 것을 확인
 코로나의 영향이라 판단
 2023년부터는 코로나 극복 후 예매수도 높아짐




나이와 관련된 무료 멤버십 등급인
 노블/썹티우미/일반 중 일반 회원이 가장 많음
 30 - 60대의 가입 수가 많다는 것을 알 수 있음
 유료 멤버십은 연회비가 비쌀 수록 많은 경향




- 성별과 나이에 따른 장르 선호도
- 40대와 30대 여성, 50대 남성은 교향곡
 - 40대 여성은 클래식 장르도 선호



- 나이 그룹별로 할인 퍼센트를 확인
무료 멤버십 중 일반등급에 해당하는
30-50대의 할인률이 가장 낮은 것을 확인



각 층마다 중앙이 인기가 많고 가장자리로 갈수록 인기가
작아지는 대칭적인 모습
돈을 주고 구매한 경우, 합창석에 앉은 경우가 많아 합창석
이 특정공연에서는 좋은 자리일 것이라 추측



04 전처리

결측치 | 이상치 | 파생변수

04 전처리

결측치 | 이상치 | 파생변수

정가 가격 알고리즘 PRICE와 할인내역을 이용해서 고객이 앉은 좌석의 정가를 찾을 수 있음
 BUT, 할인내역에 %가 없는 경우, PRICE가 0인 경우엔 좌석의 정가를 찾을 수 없는 문제점 발생



전체적인 좌석 분포 확인과 정가 복원,
 해당 공연의 전체 좌석 등급을 찾기 위해 좌석
 등급의 정가가격을 찾을 수 있는 알고리즘 설계

알고리즘 조건1

장르가 독주인 경우, EDA결과 & '비킹구르 올라
 프손 피아노 리사이틀'의 좌석배치도 확인 결과
왼쪽에 위치한 피아노로 좌석배치가 비대칭.
 따라서 장르가 독주인 경우에는 B블록과 C블록
 을 기준으로 대칭에 되게끔 알고리즘 고안



알고리즘 조건2

각층의 특정 블록은 가격을 알 수 있는 좌석이
 하나라도 있다면 **다른 블록보다 우선적으로 등급**
 이 배정. BOX석의 경우 가중치를 두지않고 같은
 층에서 우선적으로 등급이 배정되게 하였다.

알고리즘 조건3

앞의 경우에 해당하지 않는다면, **1/2/3/합청석**
 을 기준으로 등급 배정
 그 다음으로는 전체 거리를 기준으로 배정되게
 알고리즘 고안

정가 가격 알고리즘 - 사용 전 후 시각화



FREE 743 / R석 366 / S석 94 / A석 146/ B석 145

R석 739 / S석 379 / A석 212 / B석 164


04 전처리

결측치 | 이상치 | 파생변수

seat_level

seat_level의 값이 'missing'이지만 가격이 0원인 경우
'free'로 변경

running_time



공연 진행 시간인 running_time이 0인 공연 발견
주최측 문의 결과 오류인 것을 확인, 답변대로 값 수정

1. 안녕하세요. 질문 감사합니다.
대관자가 수기로 작성하는 것이라보니 인터미션 내용이 러닝타임으로 들어간것 같습니다.
0분, 즉 인터미션이 없는 공연같은경우 70분으로 환산,
인터미션이 15분인 공연인 경우는 90분으로 환산 부탁드립니다.
-빅콘테스트 사무국 메일 답변-

member_yn

member_yn이 'N'인데 멤버십 타입이 존재하는 경우
현재 기준을 기준으로 탈퇴한 회원이라 판단
따라서 **예매 당시에는 회원**이라 간주하여 'Y'로 바꿔준다

멤버십 변수


예술의 전당 회원 관련 멤버십 내역이 없는데
회원할인을 받은 경우엔 예매 당시엔 멤버십이 있었다고 판단
따라서 age_mb, gld_mb, bl_mb, grn_mb의 값 변경

age_mb

유료 멤버십(골드, 블루, 그린)이 있는데 비회원인 경우에는
age_mb를 일반으로 채워줌

사유 : 싹티우미, 일반, 노블 중 가장 비중이 높은 것은 일반
유료 회원은 대부분 일반 나이에 해당하는 30-50대가 많기
때문

초대권 이상치 초대권인데 PRICE가 50000인 경우



초대권은 수익을 얻지 못하는 0원의 개념,
따라서 논리적으로 맞지 않음
따라서 제거


차액

discount_type0이 **차액**인 경우는 할인 받을 수 있는 증빙 자료를 제출하지 못한 경우에 **추가로 지불**해야하는 돈

티켓 수령 안내

- 티켓 수령 및 현장 구매는 공연 시작 1시간 30분 전부터 가능합니다.
- 할인받은 내역이 있으신 경우 티켓 수령 시 할인 안내표에 공지되어 있는 증빙서류를 지참하시기를 바랍니다. **미지참시 정가에 대한 차액을 지불하셔야 티켓 수령이 가능합니다.**

<실제 예술의 전당 사이트 중 일부 캡처>



차액인 경우의 가격 Histogram을 봤을 때, 대체로 0에 몰려있고 가격대가 낮음

0원인 데이터는 없으며 (차액이 0원이면 데이터 오류입니다)
즉 한번도 판매되지 않았던 좌석을 점유한것처럼 보이게 하고 결제를 하여 돈을 받은 뒤 회원이 예매한 좌석을 입장 시켜주는 것입니다.
-빅콘테스트 사무국 메일 답변-

차액은 예매 데이터에 속하긴 하나 다른 데이터와 다른 특수한 상황
특히 **고객이 실제 앉은 자리를 알 수 없다는** 점에서 분석에 왜곡을 일으킴
➤ 따라서 삭제 처리

공연/고객/좌석의 특성을 살리기 위한 **17개의 파생변수** 생성
좌석그룹핑을 위한 클러스터링에서 공연/고객/좌석별로의 특징 추출 가능

공연 관련

변수명	변수 의미	사용된 변수	생성 방법
cancel_num	공연별 취소 건수	ticket_cancel	공연별 ticket_cancel이 2인 행의 수
days	공연날짜의 요일	play_date_time	월:0/ 화:1 / 수:2 / 목:3 / 금:4 / 토:5 / 일:6
tran_rate	공연의 관람 건수	ticket_cancel	ticket_cancel이 0인 행의 수
covid	코로나 사회적 거리두기단계	play_date_time	기간별 코로나 사회적 거리두기 단계
ticket_count	공연별 예매 건수	cancel_yn	관람/취소 모두 합한 예매 내역 수
min_price	공연별 제일 싼 좌석등급의 가격	R_price ~ all	공연에 매겨진 좌석 등급 중 min()

고객 관련

변수명	변수 의미	사용된 변수	생성 방법
loyalty	고객 충성도	멤버십 변수들	가중치(골드 10, 블루 4, 그린 2, 무료 1, 비회원 0)의 합
like	예매속도 (관심도)	(pre_)open_date	$(\text{play_date_time} - \text{tran_date_time}) / (\text{play_date_time} - (\text{pre_})\text{open_date})$
like_ratio	한 공연내에서의 관심도	like	like의 공연별 percentile
afford	고객의 여유 티켓자금	min_price	$\text{price} - \text{min_price}$
rev_seat	고객의 앉은 좌석의 정가	grade	grade의 해당하는 가격을 return
divide_discount	고객의 할인 타입	discount_type	0 / 정가 / 회원할인 / 외부할인

좌석 관련			
변수명	변수 의미	사용된 변수	생성 방법
cancel_yn	좌석의 실제 관람여부	tran_date_time	똑같은 좌석에 대한 예매내역의 마지막 행의 ticket_cancel이 2면 1, 아닐 시 0
seat_count	한 공연에서 특정 좌석에 대한 예매내역 수	seat	play_date_time과 seat로 gruopby.count()
distance	좌석과 무대 사이의 거리	x, y	좌석과 무대의 유클라디안 거리
angle_degrees	좌석과 무대 사이 각도	x, y	라디안 단위로 각도 계산 후 0-90도 사이로 변환
seat_hot	해당 좌석의 인기도	ticket_cancel, seat	총 예매 티켓 수 중 그 좌석의 비중을 정규화

추가 전처리

ticket_cancel 변수는 고객이 취소를 했는지 아닌지를 알 수 있음
따라서 본 분석에서 **ticket_cancel이 0인 고객은 취소 없이 공연장에서 직접 관람**을 했다고 정의
하지만 데이터 중 같은 공연, 같은 좌석에 대해 ticket_cancel이 0인 행이 중복해서 나타남

	play_datetime	seat	좌석수
0	2020-11-26 20:00:00	1층 B블록15열 11	72
1	2020-07-23 20:00:00	1층 B블록3열 7	67
2	2021-04-01 20:00:00	3층 B블록4열 6	64
3	2020-11-26 20:00:00	1층 B블록1열 4	46
4	2021-07-02 20:00:00	3층 C블록4열 5	31
...	...	...	...
24651	2023-07-01 17:00:00	1층 B블록2열 3	2
24652	2019-10-08 20:00:00	1층 C블록11열 5	2
24653	2021-10-01 19:30:00	1층 B블록8열 1	2
24654	2021-12-03 19:30:00	2층 B블록5열 2	2
24655	2019-10-19 17:00:00	1층 B블록2열 6	2

24656 rows x 3 columns


» 이는 논리적 오류라 판단,
따라서 중복인 경우 tran_date를 기준으로 마지막 고객을 제외하고 모두 제거

추가 전처리

공연 제목은 같지만 다른 날짜, 다른 시간대에 한 공연도 performance_code가 같아 구분이 되지 않음.
따라서 **unique한 공연**을 구분할 수 있는 label 변수 생성


앞서 만든 파생변수중 cancel_yn은 내가 예매했었던 좌석이 최종적으로 관람/취소 됐는지 구분 가능
하지만 cancel_yn이 10이면서 ticket_cancel이 00이 되는 행은 논리적 오류에 해당, 따라서 제거

추가 EDA




클래식, 교향곡, 합창인 경우는 가운데에 몰리는 경향이 있었지만 3층까지도 꽤나 많이 분포된 것으로 보아 규모가 크고 인기가 많은 공연들이라고 판단

추가 EDA



성악, 오페라, 실내악인 경우 앞쪽에 몰려있는 분포를 띄어서
규모가 작은 공연이라고 판단

추가 EDA



좌석 복구에서 언급 했듯이 독주의 경우 왼쪽으로 치우쳐져있는 분포
이는 피아노가 좌측에서 공연하기 때문이라고 확인



05 좌석 그룹핑


분석프로세스 | 공연별 | 좌석별

05 좌석그룹핑

분석프로세스


공연별

좌석별




- 분석의 목표는 수익을 최대화 시키는 것
- 따라서 **돈을 지불하고 공연을 관람**한 고객들에 대해서만 좌석그룹핑을 진행

K-means 클러스터링 수행




군집 수 k =4로 진행



공연 변수 중 like와 tran_rate로 클러스터링 진행

군집별 변수들에 대한 boxplot 시각화



0번 클러스터

관심도가 낮으며 예매율이 높은 공연
군집별 박스플랏 확인 시
가격대가 낮으며 실제로 본 사람이 많은 공연임
따라서 좋은 퀄리티의 공연이 아니지만 가격이 낮다는 이
점 때문에 사람들이 많이 찾는 공연

1번 클러스터

관심도가 높고 예매율도 높은 공연
가격대가 높고, 공연 구매활동이 활발한 공연
따라서 인기와 수요가 높아 가격대가 높게 형성된 공연


2번 클러스터

관심도가 낮고 예매율도 낮은 공연
가격대가 낮고, 공연 구매활동도 저조한 공연
따라서 인기와 수요가 낮아 다른 공연들에 비해 가격도
저렴하게 책정된 공연

3번 클러스터

관심도가 높고, 예매율이 높은 공연
가격대가 높지만 실제로 보러오는 사람이 없는 공연
따라서 특정 수요층에게만 인기가 있는 공연

k-means 클러스터링



고객 변수 중
seat_hot과 like를 축으로 하여 클러스터링 진행

k-means 클러스터링

0번 클러스터

인기 없는 자리를 빨리 예매한 사람들
공연의 인기가 너무 많아 매진이 빨리 된 경우

1번 클러스터

인기있는 좌석을 느리게 예매한 사람들
정말 퀄리티 낮은 공연을 보러간 경우

2번 클러스터

인기 있는 자리를 빨리 예매한 사람들
퀄리티 좋고 인기 많은 공연을 예매하려고 한 경우


3번 클러스터

인기없는 좌석을 느리게 예매한 경우
특히 충성도(loyalty)가 낮은 고객이 많음




06 결론

최종분석결과 | 기대효과 | 활용방안




1. 가격이 낮아서 사람들이 많이 오는 공연(0번 클러스터)
고객1번군집이 많음, 나머지는 비슷한 비율
확실히 퀄리티 낮은 공연에 대해서는
좋지 않은 공연만 보러가는 고객들이 많이 분포한다.

가격에 민감




2. 인기많은공연(1번 공연클러스터) : 고객2번군집이 많이옴.
고객2번군집은 인기있는 자리를 빨리 예매한 고객들이었음.
인기가 많은 공연에 대해서는 확실히 공연에 대한 관심도가 높다

가격 민감도가 낮은 고객



3. 인기,수요가 낮아 싼 가격의 공연(공연 2번 클러스터)
1번고객군집이 제일 많다
정말 퀄리티가 낮은 공연들이었고, 실제로 저렴한 가격을 원하는 고객만 이용하는 추세
가격에 민감



4. 특정 수요층에만 인기있는공연(3번공연 클러스터)
2번고객군집이 주로 관람을 하러감.
특정 마니아들은 관심이 많아서 예매를 빨리 하는 추세,
3번 고객군집의 비율이 제일 작음.
충성도 낮은 고객들이 별로 없다는것.
→ 특정 수요층은 항상 보러온다는 것.
가격 민감도가 낮은 고객

현실적인 상황에서도 쓸 수 있는 가격책정 알고리즘

가격책정의 선택과 판단은 오롯이 대관자와 예술의 전당 측에 있기에 주최 측의 시각에서 제한된 정보를 가지고 가격 책정을 할 수 있는 방법을 고안
예매율과 공연의 고객층처럼, 경험적으로 알고 있는 공연의 경향이 있을 것이
라 생각하여, 그러한 정보를 바탕으로 가격 책정과 좌석 그룹핑을 어떻게 하는
편이 좋을지 다른 비슷한 공연과 비교한 인사이트를 제공한다.
또한 효과적인 고객의 가격 책정을 위해 어떤 변수를 살펴봐야 하는지, 어떤 고
객을 타겟으로 해야 이익이 올라가는지 알려줌으로써 더 명확한 가이드라인을
제공하고 고객을 유도할 수 있는 효과적인 전략을 펼 수 있다.

